11기 정규과정 4주차

ToBig's 10기 이민주

PCA & t-SNE

Contents

Unit 01 | Intro : Dimensionality Reduction

Dimensionality Reduction ??

차원 축소

Unit 01 | Intro : Dimensionality Reduction

Curse of Dimensionality ??

차원의 저주

Unit 01 | Intro : Dimensionality Reduction

- **Curse of Dimensionality 차원의 저주**

  : 변수가 늘어나고 차원*이 커지면서 발생하는 문제

* Dimension 차원 : 축(변수)의 개수

Unit 01 | Intro : Dimensionality Reduction

- **Curse of Dimensionality 차원의 저주**

  : 변수가 늘어나고 차원이 커지면서 발생하는 문제

  - 필요한 데이터의 수 기하급수적으로 증가

1차원

1	2	3

2차원

1	2	3
4	5	6
7	8	9

3차원

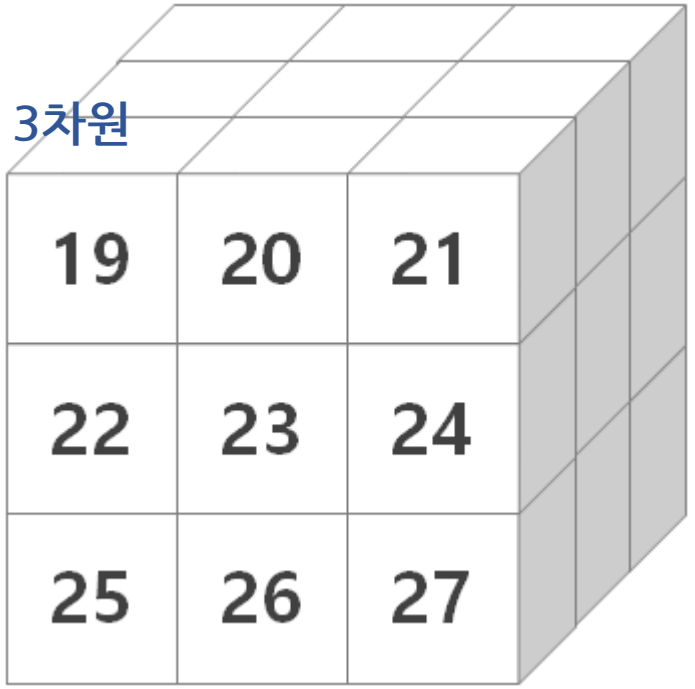

Unit 01 | Intro : Dimensionality Reduction

- **Curse of Dimensionality 차원의 저주**

  : 변수가 늘어나고 차원이 커지면서 발생하는 문제

  - 필요한 데이터의 수 기하급수적으로 증가

  - 데이터의 크기가 정해진 경우,
    차원공간의 희소성이 증가 & 데이터의 밀도 감소

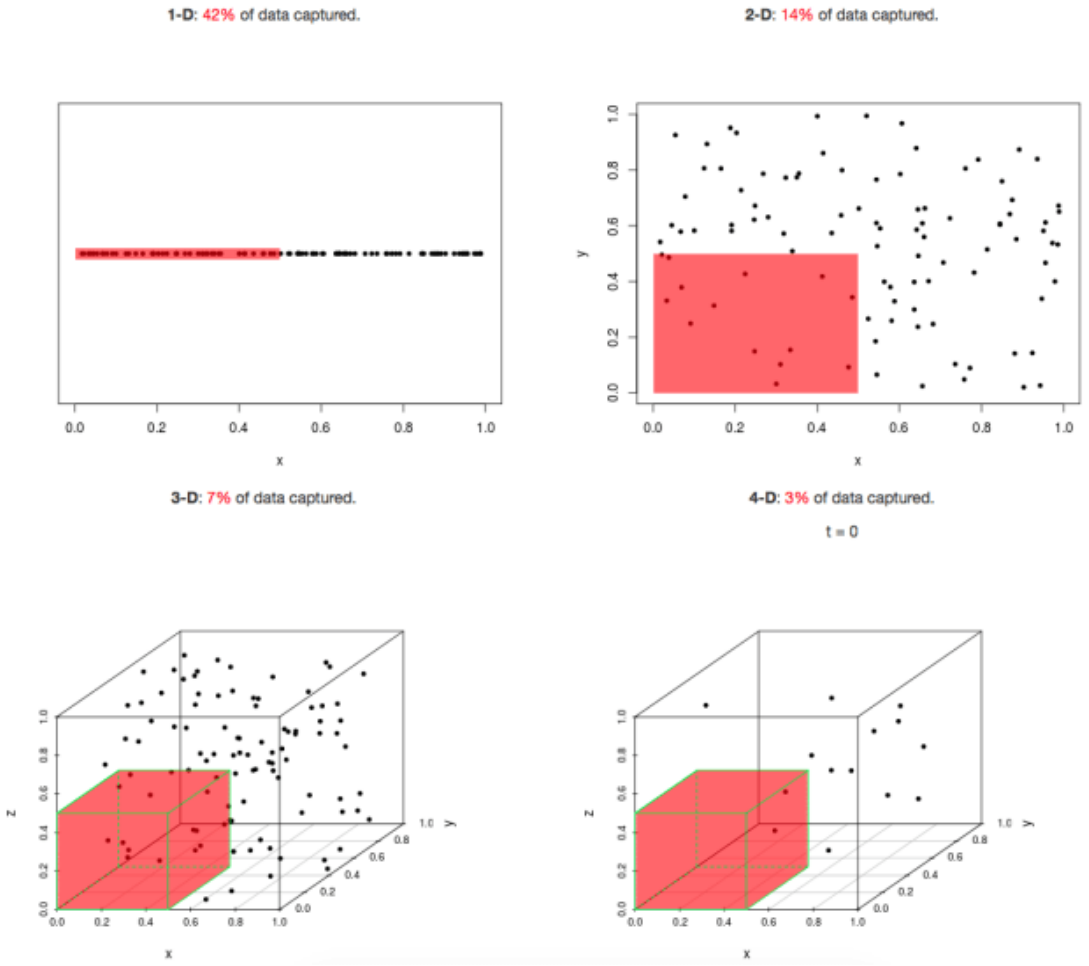

Unit 01 | Intro : Dimensionality Reduction

- **Curse of Dimensionality 차원의 저주**

  : 변수가 늘어나고 차원이 커지면서 발생하는 문제

  - 필요한 데이터의 수 기하급수적으로 증가

  - 데이터의 크기가 정해진 경우,
    차원공간의 희소성이 증가 & 데이터의 밀도 감소

  - 오버피팅 확률 증가 & 성능 감소

  - 연산량 급증

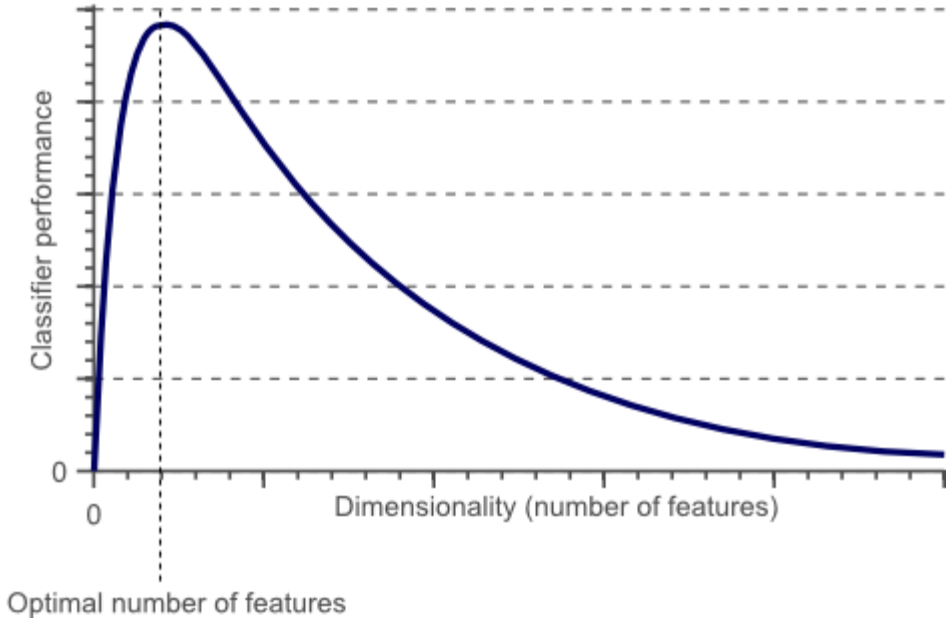

Unit 01 | Intro : Dimensionality Reduction

Dimensionality Reduction !!

차원 축소

Unit 01 | Intro : Dimensionality Reduction

- **Dimensionality Reduction 차원축소**

  : 데이터의 특징을 잘 나타내는 변수만 사용해 차원 수를 줄이는 방법

  ➔ 차원의 저주를 해결 & 시각화 용이 & 데이터 특성 파악 용이 & 컴퓨팅파워 절약

1. Feature Selection 변수 선택

: 변수들 중 중요한 변수만 선택하고
나머지 변수는 버림

A, B, C, D, E ➔ A, D

정보손실이 많음

2. Feature Extraction 변수 추출

: 모든 변수를 조합해서 데이터를
잘 표현할 수 있는 새로운 변수 추출

A, B, C, D, E ➔ 가, 나

모든 정보 사용

가 : f(A,B,C,D,E)
나 : g(A,B,C,D,E)

Unit 01 | Intro : Dimensionality Reduction

- **Dimensionality Reduction 차원축소**

  : 데이터의 특징을 잘 나타내는 변수만 사용해 차원 수를 줄이는 방법

  ➔ 차원의 저주를 해결 & 시각화 용이 & 데이터 특성 파악 용이 & 컴퓨팅파워 절약

1. Feature Selection 변수 선택

   : 변수들 중 중요한 변수만 선택하고

   나머지 변수는 버림

   A, B, C, D, E ➔ A, D

2. Feature Extraction 변수 추출

   : 모든 변수를 조합해서 데이터를

   잘 표현할 수 있는 새로운 변수 추출

   PCA

   A, B, C, D, E ➔ 가, 나

Unit 02 | Eigen Decomposition

▪ Eigenvector 고유벡터 & Eigenvalue 고유값

정방대칭행렬 A에 대해,

- Eigenvector 고유벡터 : K $AK=\lambda K$
  : 선형변환 A를 했을 때, 방향이 변하지 않는 벡터
- Eigenvalue 고유값 : λ $det(A-\lambda I)=0$
  : 벡터의 크기가 변하는 정도

A : n * n행렬

K : k1,k2,…,kn
n개의 n*1 행렬(벡터)
➔ 단위 길이(길이 = 1) & 서로 직교

λ : λ1, λ2,…, λn
n개의 스칼라값

Unit 02 | Eigen Decomposition

▪ Eigenvector 고유벡터 & Eigenvalue 고유값

$AK=\lambda K$ $\det(A-\lambda I)=0$

$n=2$

2x2 정방행렬 $A=\begin{pmatrix}2 & 1\\ 1 & 2\end{pmatrix}$

$$\det|A-\lambda I|=\det\begin{vmatrix}2-\lambda & 1\\ 1 & 2-\lambda\end{vmatrix}=(2-\lambda)^2-1$$

ad-bc

$$=\lambda^2-4\lambda+3$$

$$=(\lambda-1)(\lambda-3)$$

$\therefore \lambda_1=1,\ \lambda_2=3$

$\lambda=1$

$$A\begin{pmatrix}k_1\\ k_2\end{pmatrix}=\lambda\begin{pmatrix}k_1\\ k_2\end{pmatrix}$$

$$\begin{pmatrix}2 & 1\\ 1 & 2\end{pmatrix}\begin{pmatrix}k_1\\ k_2\end{pmatrix}=\begin{pmatrix}2k_1+k_2\\ k_1+2k_2\end{pmatrix}=\begin{pmatrix}k_1\\ k_2\end{pmatrix}$$

$\therefore k_1=-k_2$

$$\begin{pmatrix}k_1\\ k_2\end{pmatrix}=\begin{pmatrix}1\\ -1\end{pmatrix}\ *\ 1/\sqrt{2}$$

$\lambda=3$

$$A\begin{pmatrix}k_1\\ k_2\end{pmatrix}=\lambda\begin{pmatrix}k_1\\ k_2\end{pmatrix}$$

$$\begin{pmatrix}2 & 1\\ 1 & 2\end{pmatrix}\begin{pmatrix}k_1\\ k_2\end{pmatrix}=\begin{pmatrix}2k_1+k_2\\ k_1+2k_2\end{pmatrix}=\begin{pmatrix}3k_1\\ 3k_2\end{pmatrix}$$

$\therefore k_1=k_2$

$$\begin{pmatrix}k_1\\ k_2\end{pmatrix}=\begin{pmatrix}1\\ 1\end{pmatrix}\ *\ 1/\sqrt{2}$$

Unit 02 | Eigen Decomposition

▪ Eigenvector 고유벡터 & Eigenvalue 고유값

- Eigenvector 선형변환 A를 했을 때, 방향이 변하지 않는 벡터
- Eigenvalue 벡터의 크기가 변하는 정도

$A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$ 변환

$\lambda=1 \rightarrow \begin{pmatrix} 1/\sqrt{2} \\ -1/\sqrt{2} \end{pmatrix}$

$\lambda=3 \rightarrow \begin{pmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix}$

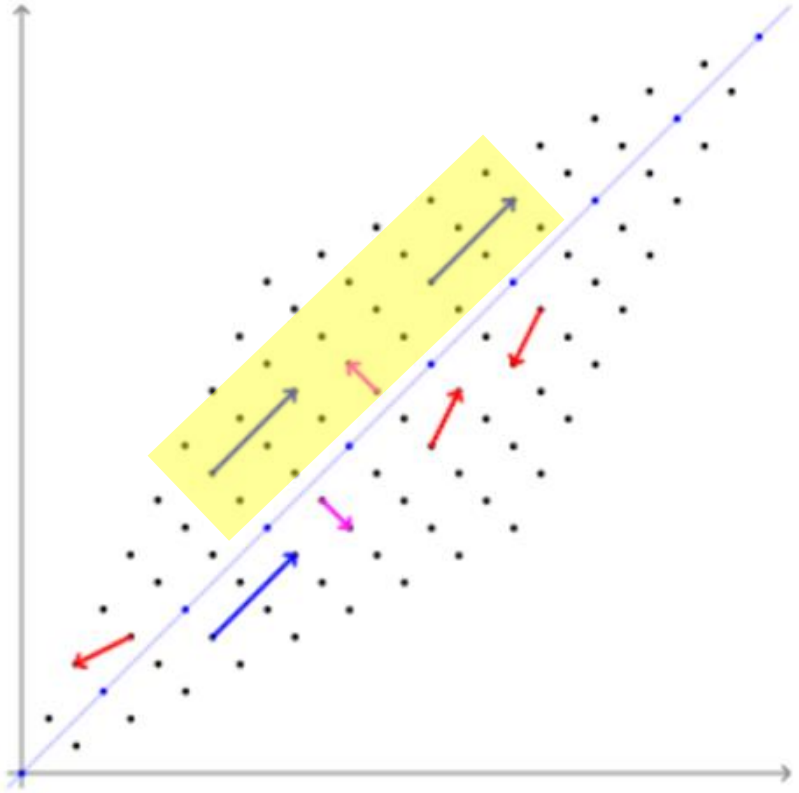

Unit 02 | Eigen Decomposition

▪ Spectral Decomposition 스펙트럼 분해

n차 대칭행렬 A

$$A = \lambda1*k1*k1' + \lambda2*k2*k2' + \cdots + \lambda n*kn*kn'$$

$$= \Sigma\ \lambda i*ki*ki'$$

$$= [k1\ k2\ \cdots\ kn]\begin{bmatrix}\lambda1 & \cdots & 0\\ 0 & \lambda2 & 0\\ \vdots & \ddots & \vdots\\ 0 & \cdots & \lambda n\end{bmatrix}\begin{bmatrix}k1'\\ k2'\\ \vdots\\ kn'\end{bmatrix}$$

$$= P\Lambda P \quad (\text{단, } PP' = P'P = I)$$

P : 고유벡터의 열로 구성된 행렬
Λ : 고유값을 대각원소로 하는 대각행렬

n차 양정치행렬* A의 성질

$$**tr(A) = tr(P\Lambda P') = tr(P'P\Lambda)$$

$$= tr(\Lambda) = \Sigma\ \lambda i$$

*양의 정부호 행렬 == 양정치행렬

**tr : trace, 행렬의 대각합

***공분산행렬은 언제나 양정치행렬

Unit 02 | Eigen Decomposition

▪ Spectral Decomposition 스펙트럼 분해

n차 대칭행렬 A

$$A = \lambda1*k1*k1' + \lambda2*k2*k2' + \cdots + \lambda n*kn*kn'$$

$$= \Sigma\ \lambda i*ki*ki'$$

$$= [k1\ k2\ \cdots\ kn]\begin{bmatrix}\lambda1 & \cdots & 0\\ 0 & \lambda2 & 0\\ \vdots & \ddots & \vdots\\ 0 & \cdots & \lambda n\end{bmatrix}\begin{bmatrix}k1'\\ k2'\\ \vdots\\ kn'\end{bmatrix}$$

$$= P\Lambda P \quad (\text{단, } PP' = P'P = I)$$

코드로 !

P : 고유벡터의 열로 구성된 행렬
Λ : 고유값을 대각원소로 하는 대각행렬

n차 양정치행렬* A의 성질

$$**tr(A) = tr(P\Lambda P') = tr(P'P\Lambda)$$

$$= tr(\Lambda) = \Sigma\ \lambda i$$

*양의 정부호 행렬 == 양정치행렬

**tr : trace, 행렬의 대각합

***공분산행렬은 언제나 양정치행렬

Unit 03 | PCA : Principal Component Analysis

- ## Principal Component Analysis 주성분분석

  : 변수들의 전체 분산을 최대한 설명하는 소수의 주성분을 통해 분석하는 방법

  ➔ 데이터의 구조 최대한 유지

  ➔ 서로 상관관계가 있는 변수들 사이의 복잡한 구조를 좀 더 간편하게 변환

  ➔ 기하학적 측면, 좌표축을 회전시켜 얻어진 새로운 좌표축을 선택

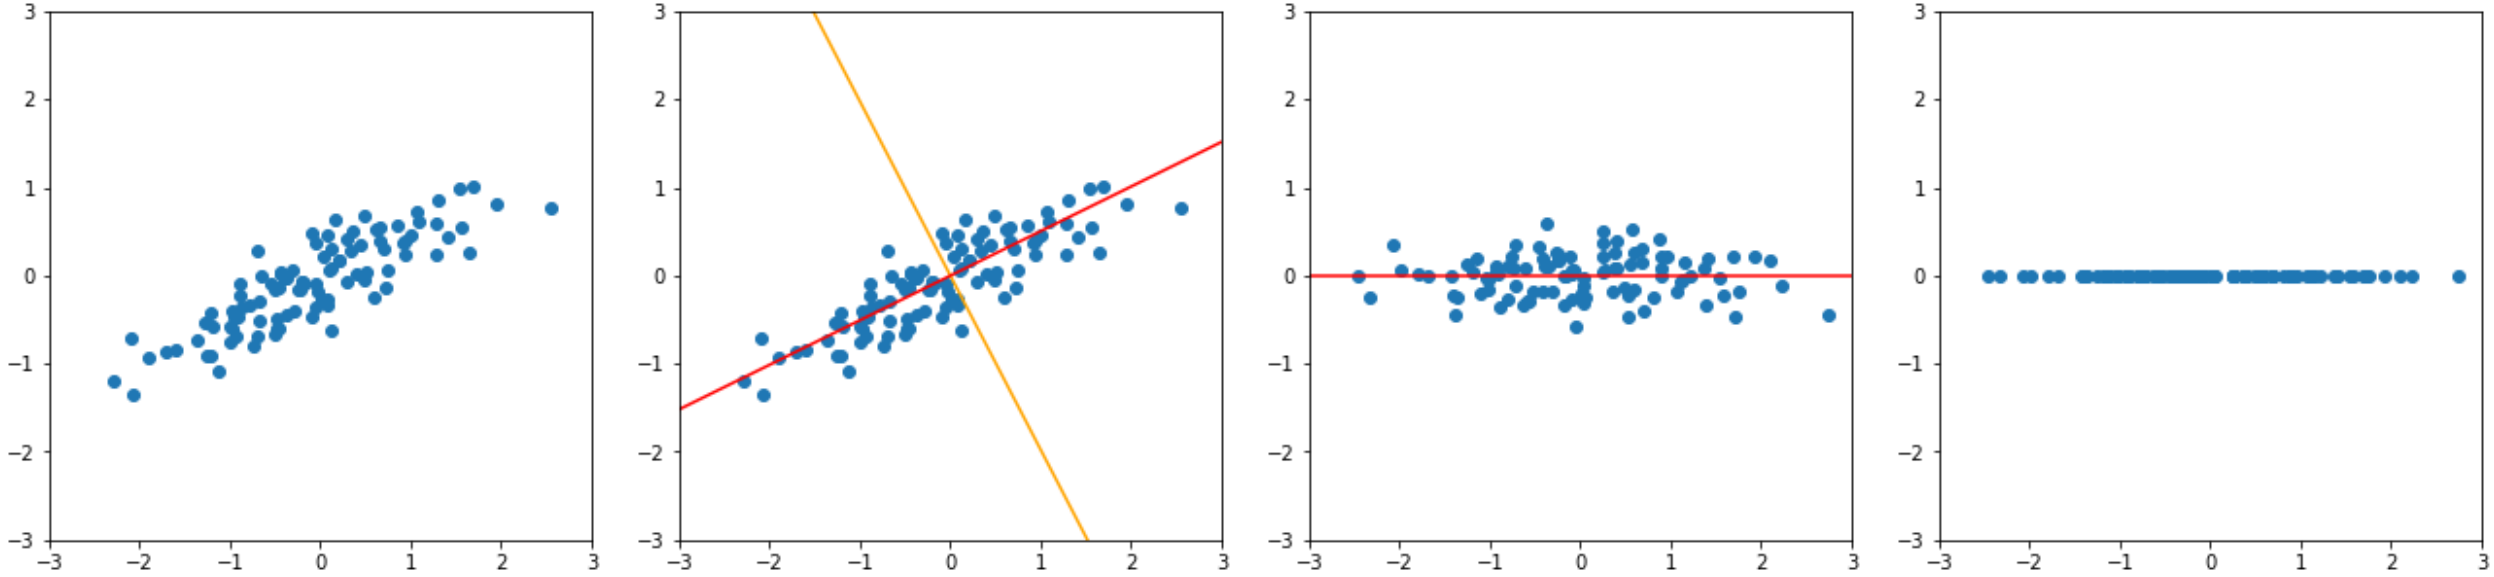

Unit 03 | PCA : Principal Component Analysis

- Principal Component Analysis 주성분분석

공분산행렬

$$\Sigma = \begin{pmatrix} 0.879 & 0.415 \\ 0.415 & 0.268 \end{pmatrix}$$

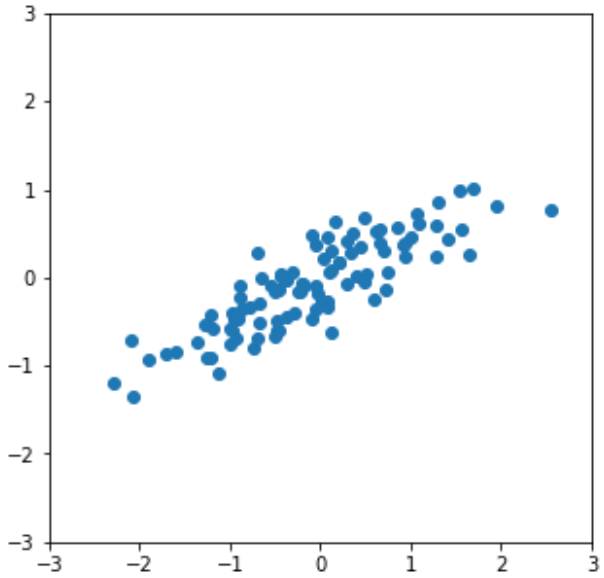

Unit 03 | PCA : Principal Component Analysis

- Principal Component Analysis 주성분분석

공분산행렬

$$\Sigma = \begin{pmatrix} 0.879 & 0.415 \\ 0.415 & 0.268 \end{pmatrix}$$

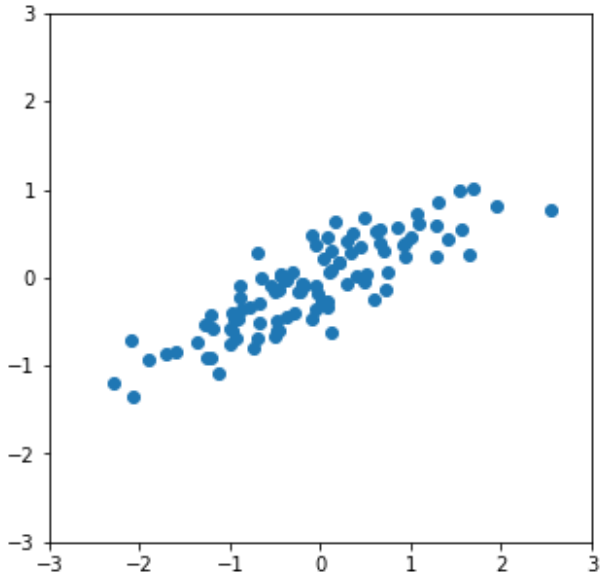

공분산행렬 Σ 변환

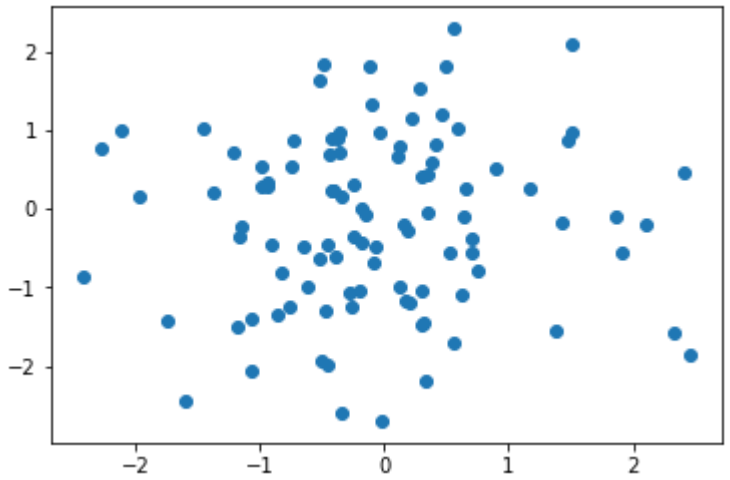

Unit 03 | PCA : Principal Component Analysis

▪ Principal Component Analysis 주성분분석

공분산행렬

$$\Sigma = \begin{pmatrix} 0.879 & 0.415 \\ 0.415 & 0.268 \end{pmatrix}$$

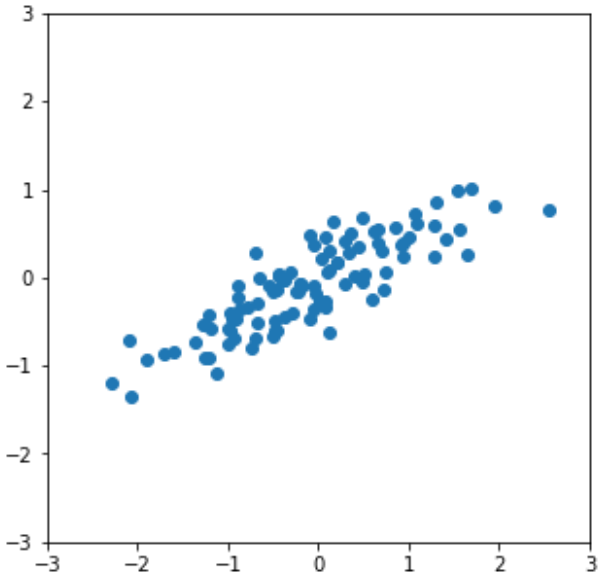

공분산행렬 스펙트럼 분해

$$\Sigma = \begin{pmatrix} 0.879 & 0.415 \\ 0.415 & 0.268 \end{pmatrix}$$

$$= P\Lambda P'$$

$$= \begin{pmatrix} 0.8923 & -0.4514 \\ 0.4513 & 0.8923 \end{pmatrix} \begin{pmatrix} 1.089 & 0 \\ 0 & 0.0058 \end{pmatrix} \begin{pmatrix} 0.8923 & 0.4513 \\ -0.4514 & 0.8923 \end{pmatrix}$$

Unit 03 | PCA : Principal Component Analysis

▪ Principal Component Analysis 주성분분석

공분산행렬

$$\Sigma = \begin{pmatrix} 0.879 & 0.415 \\ 0.415 & 0.268 \end{pmatrix}$$

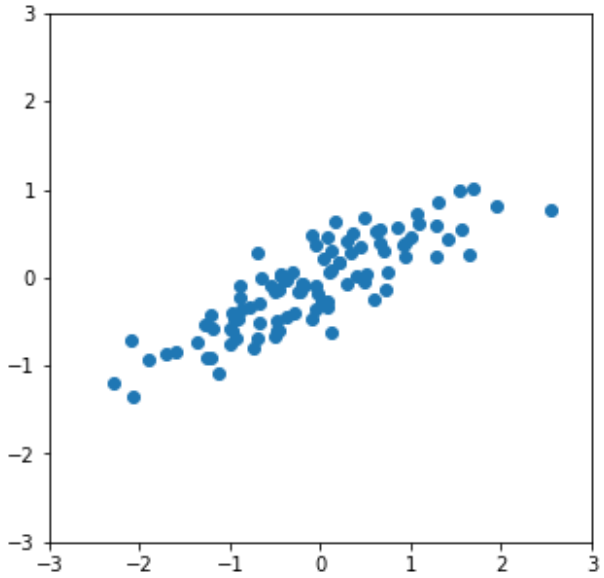

공분산행렬 스펙트럼 분해

$$\Sigma = \begin{pmatrix} 0.879 & 0.415 \\ 0.415 & 0.268 \end{pmatrix}$$

$$= P\Lambda P'$$

$$= \begin{pmatrix} 0.8923 & -0.4514 \\ 0.4513 & 0.8923 \end{pmatrix} \begin{pmatrix} 1.089 & 0 \\ 0 & 0.0058 \end{pmatrix} \begin{pmatrix} 0.8923 & 0.4513 \\ -0.4514 & 0.8923 \end{pmatrix}$$

λ1 (1.089)

k1 (0.8923, 0.4513) k2 (−0.4514, 0.8923) λ2 (0.0058)

Unit 03 | PCA : Principal Component Analysis

- Principal Component Analysis 주성분분석

공분산행렬

$$\Sigma = \begin{pmatrix} 0.879 & 0.415 \\ 0.415 & 0.268 \end{pmatrix}$$

$\lambda 1 = 1.089$ & $k1 = \begin{pmatrix} 0.8923 \\ 0.4513 \end{pmatrix}$

$\lambda 2 = 0.058$ & $k2 = \begin{pmatrix} -0.4514 \\ 0.8923 \end{pmatrix}$

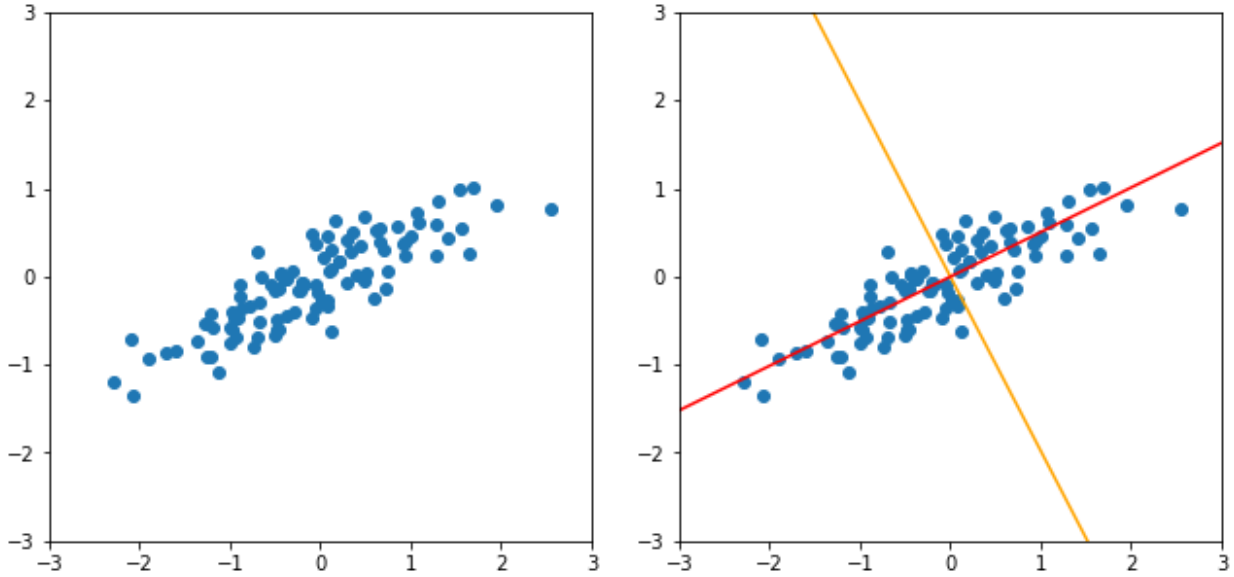

Unit 03 | PCA : Principal Component Analysis

▪ Principal Component Analysis 주성분분석

공분산행렬

$$\Sigma = \begin{pmatrix} 0.879 & 0.415 \\ 0.415 & 0.268 \end{pmatrix}$$

$$\lambda 1 = 1.089 \;\&\; k1 = \begin{pmatrix} 0.8923 \\ 0.4513 \end{pmatrix}$$

$$\lambda 2 = 0.058 \;\&\; k2 = \begin{pmatrix} -0.4514 \\ 0.8923 \end{pmatrix}$$

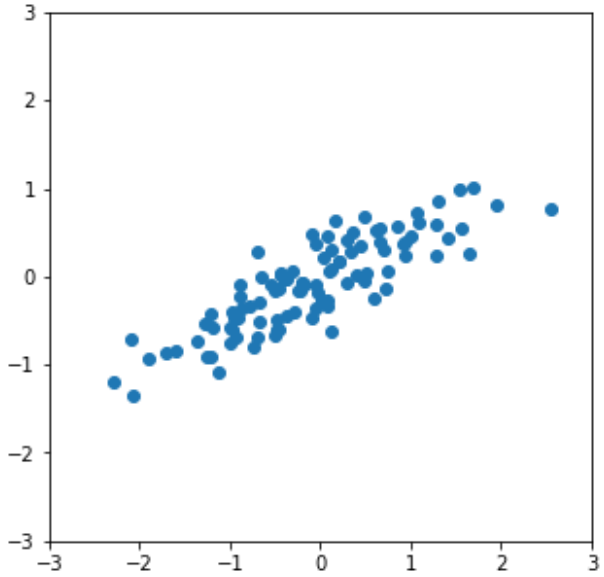

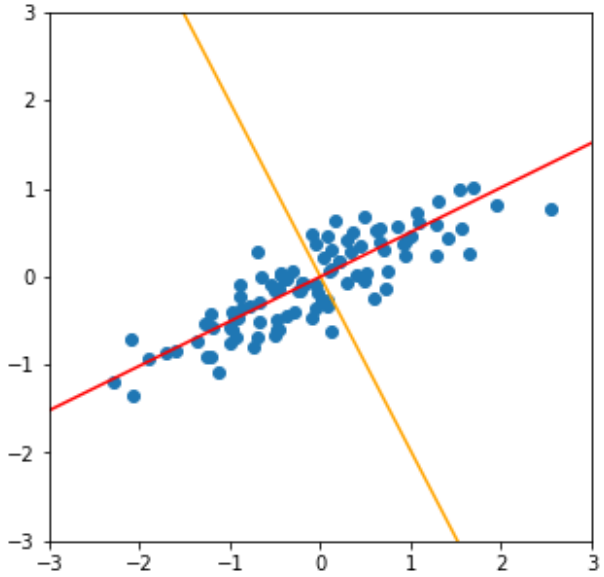

고유벡터 : 데이터가 분산된 방향

고유값 : 전체분산에 대한
주성분 PCi의 설명비율

total variance = tr(Σ) = tr(Λ) = λ1 + … + λn

var(PCi) = λi

➔ 고유값이 큰 것부터 사용

➔ 처음 k개 주성분의 설명비율
= (λ1+⋯+ λk) / total variance

Unit 03 | PCA : Principal Component Analysis

▪ Principal Component Analysis 주성분분석

공분산행렬

$$\Sigma = \begin{pmatrix} 0.879 & 0.415 \\ 0.415 & 0.268 \end{pmatrix}$$

$$\lambda 1 = 1.089 \;\&\; k1 = \begin{pmatrix} 0.8923 \\ 0.4513 \end{pmatrix}$$

$$\lambda 2 = 0.058 \;\&\; k2 = \begin{pmatrix} -0.4514 \\ 0.8923 \end{pmatrix}$$

고유벡터 : 데이터가 분산된 방향

고유값 : 전체분산에 대한
주성분 PCi의 설명비율

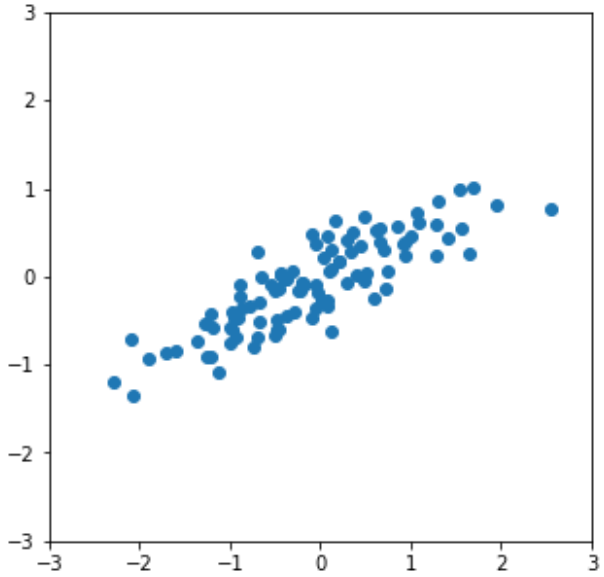

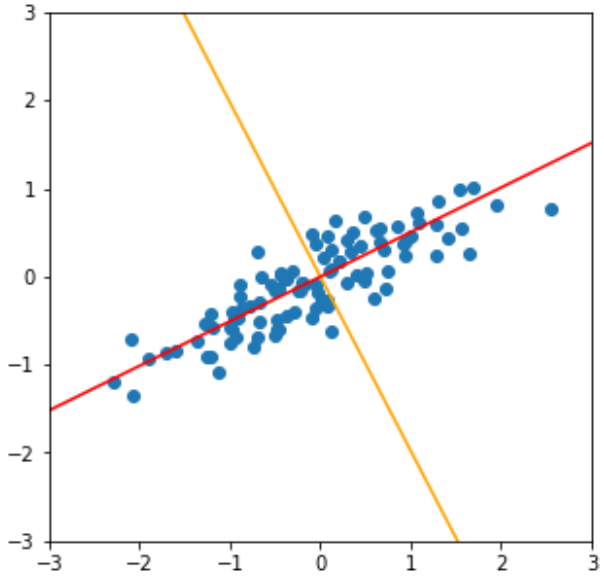

total variance = tr(Σ) = tr(Λ) = λ1 + … + λn

var(PCi) = λi

0.879(σ1^2) + 0.268(σ2^2)

= 1.089(λ1) + 0.058(λ2) = 1.147

PC1의 설명력 = 1.089/1.147 = 0.9494

PC2의 설명력 = 0.058/1.147 = 0.0506

Unit 03 | PCA : Principal Component Analysis

▪ Principal Component Analysis 주성분분석

공분산행렬

$$\Sigma = \begin{pmatrix} 0.879 & 0.415 \\ 0.415 & 0.268 \end{pmatrix}$$

$\lambda 1 = 1.089$ & $k1 = \begin{pmatrix} 0.8923 \\ 0.4513 \end{pmatrix}$

$\lambda 2 = 0.058$ & $k2 = \begin{pmatrix} -0.4514 \\ 0.8923 \end{pmatrix}$

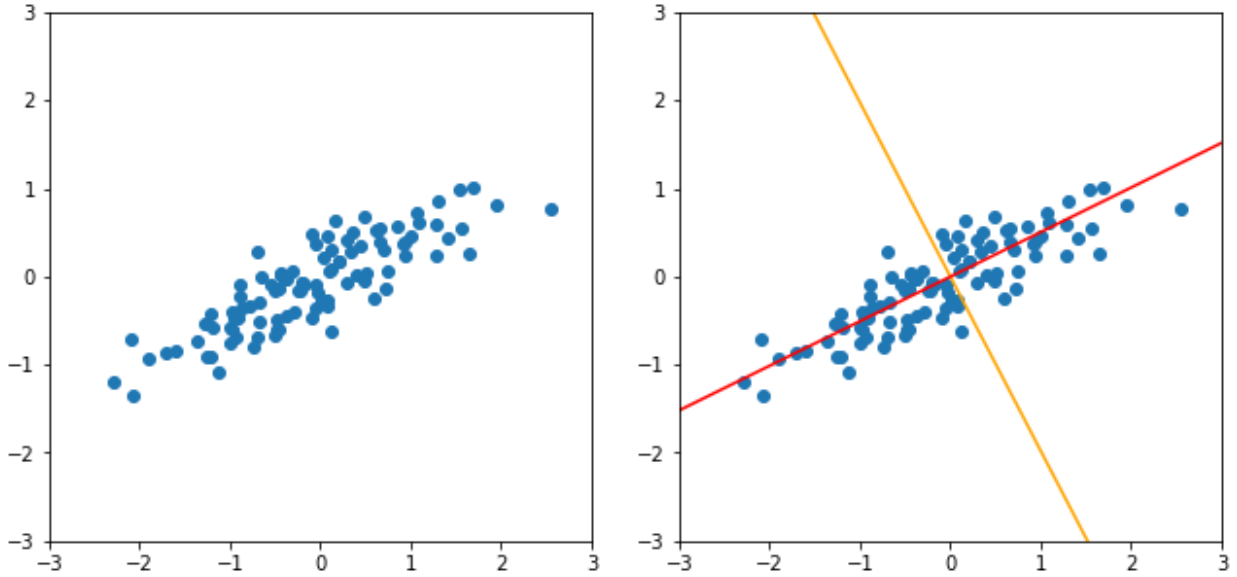

단! 공분산의 문제점 존재

- 측정단위에 영향을 받음
- 정규화 사용

$$\rho = \begin{pmatrix} 1.0 & 0.858 \\ 0.858 & 1.0 \end{pmatrix}$$

$\lambda 1 = 1.858$ ➔ $\begin{pmatrix} 0.707 \\ 0.707 \end{pmatrix}$

$\lambda 2 = 0.142$ ➔ $\begin{pmatrix} -0.707 \\ 0.707 \end{pmatrix}$

Unit 03 | PCA : Principal Component Analysis

▪ Principal Component Analysis 주성분분석

공분산행렬

$$\Sigma = \begin{pmatrix} 0.879 & 0.415 \\ 0.415 & 0.268 \end{pmatrix}$$

$\lambda 1 = 1.089$ & $k1 = \begin{pmatrix} 0.8923 \\ 0.4513 \end{pmatrix}$ 고유벡터 직교

$\lambda 2 = 0.058$ & $k2 = \begin{pmatrix} -0.4514 \\ 0.8923 \end{pmatrix}$

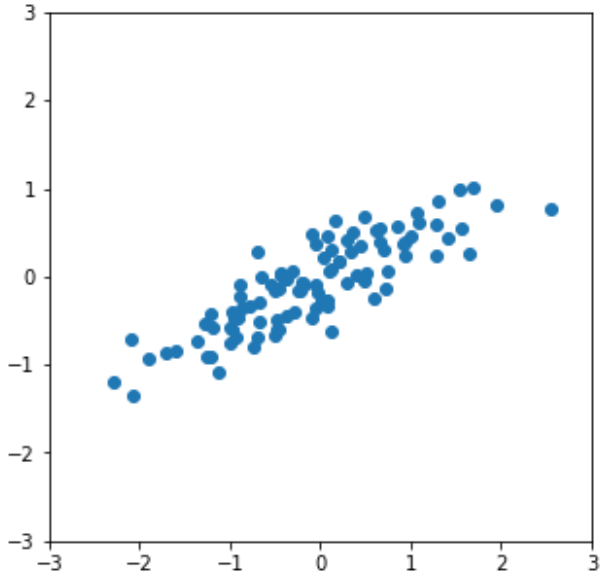

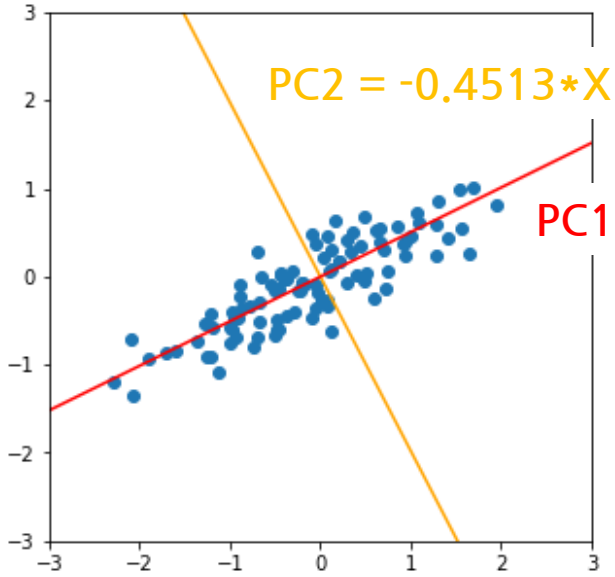

Unit 03 | PCA : Principal Component Analysis

- Principal Component Analysis 주성분분석

공분산행렬

$$\Sigma = \begin{pmatrix} 0.879 & 0.415 \\ 0.415 & 0.268 \end{pmatrix}$$

$\lambda 1 = 1.089$ & $k1 = \begin{pmatrix} 0.8923 \\ 0.4513 \end{pmatrix}$

$\lambda 2 = 0.058$ & $k2 = \begin{pmatrix} -0.4514 \\ 0.8923 \end{pmatrix}$

회전

주성분1만 사용

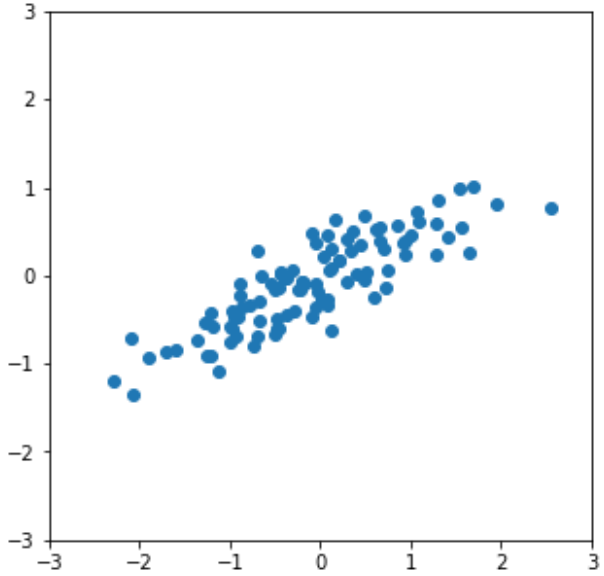

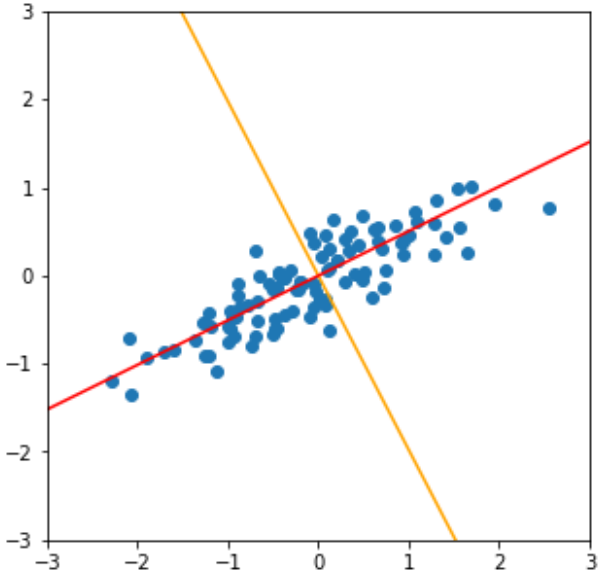

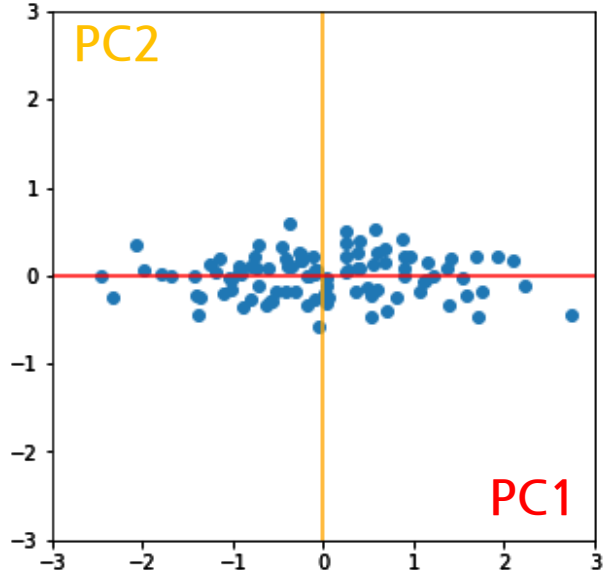

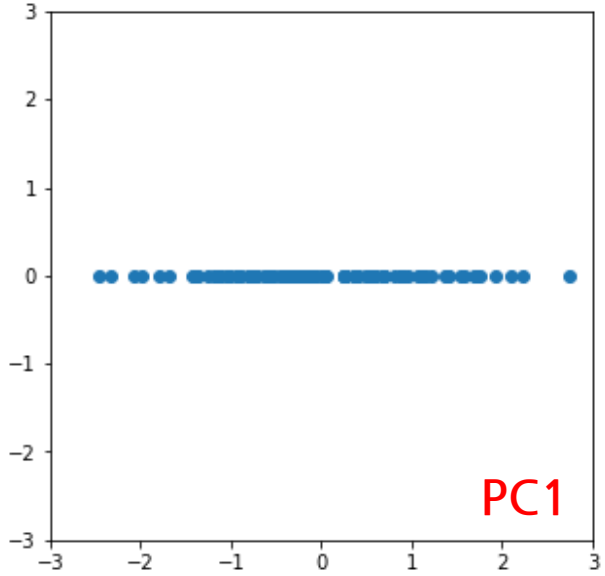

Unit 03 | PCA : Principal Component Analysis

- ## Principal Component Analysis 주성분분석

  : 변수들의 전체 분산을 최대한 설명하는 소수의 주성분을 통해 분석하는 방법

  ➔ 데이터의 구조 최대한 유지

  ➔ 서로 상관관계가 있는 변수들 사이의 복잡한 구조를 좀 더 간편하게 변환

  ➔ 기하학적 측면, 좌표축을 회전시켜 얻어진 새로운 좌표축을 선택

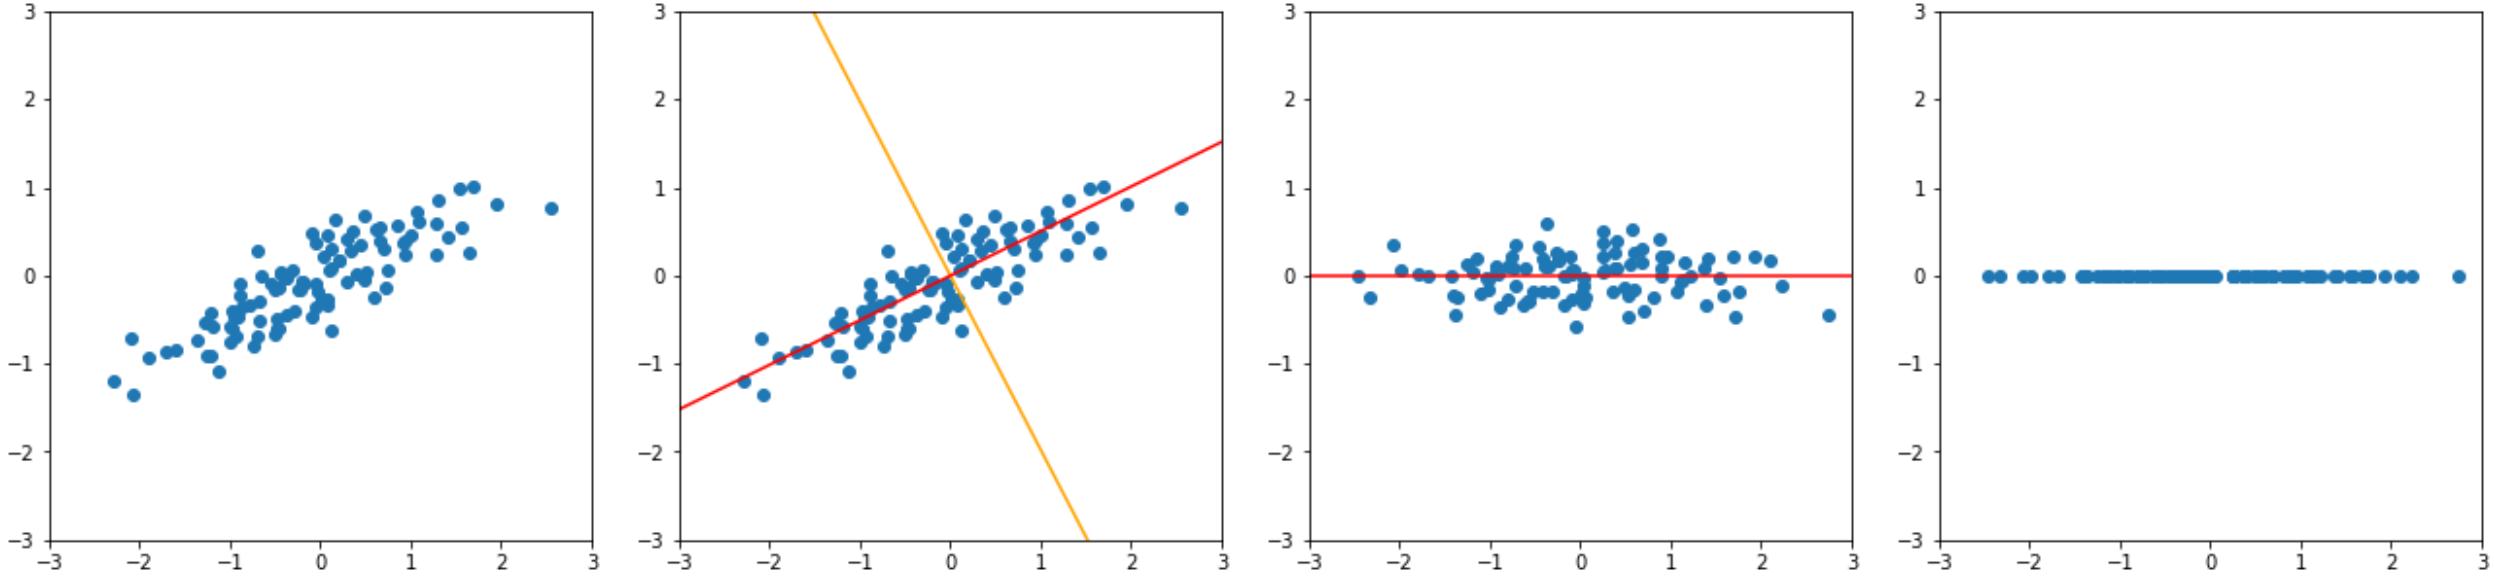

Unit 03 | PCA : Principal Component Analysis

- Principal Component Analysis 주성분분석

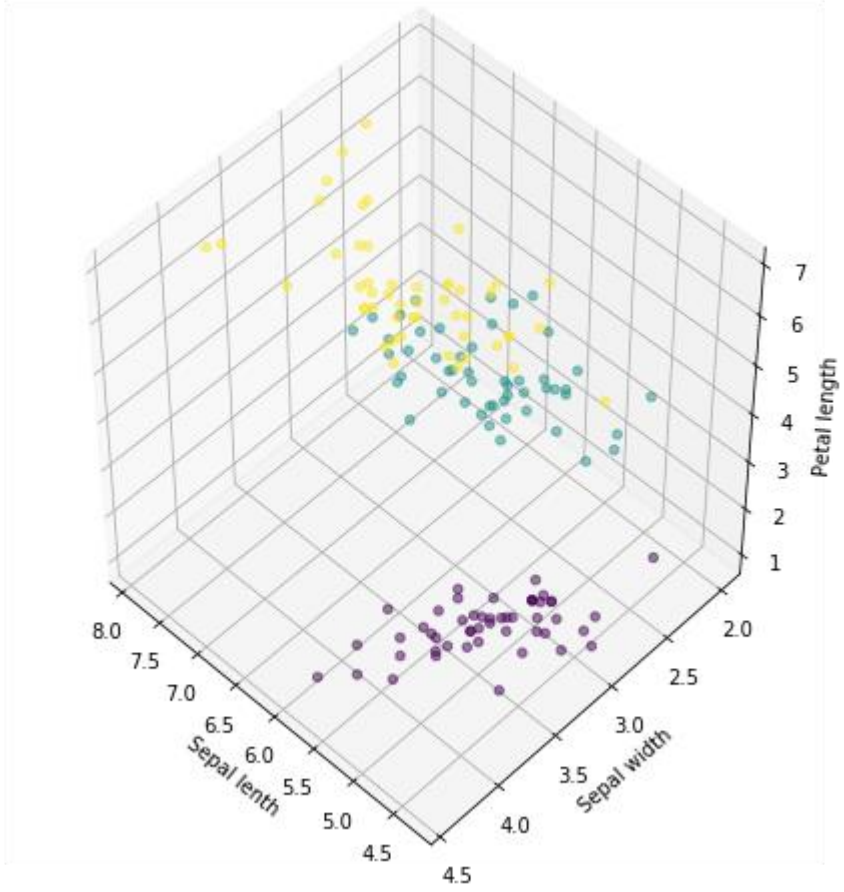

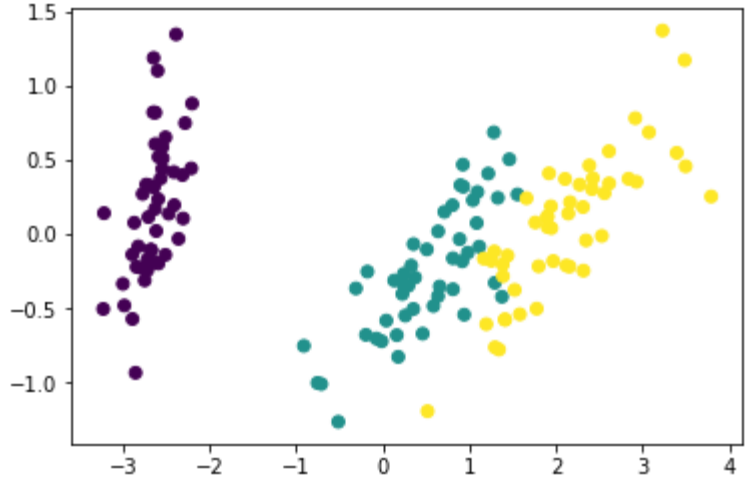

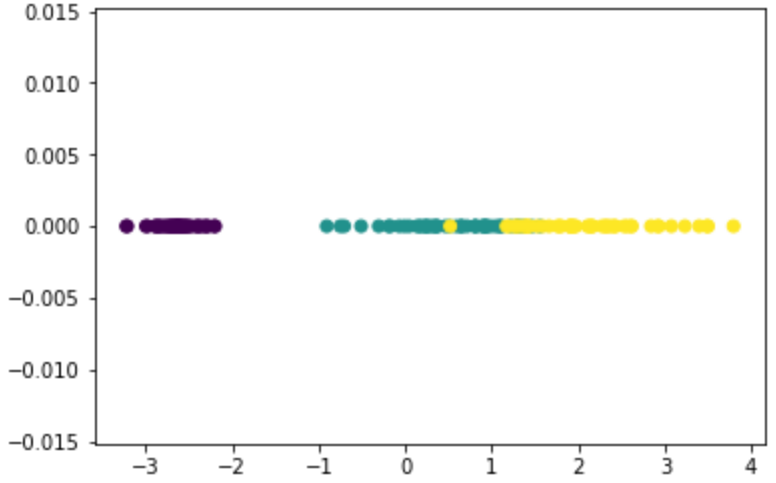

Unit 03 | PCA : Principal Component Analysis

- **주성분의 개수 k 결정**

<Scree plot>

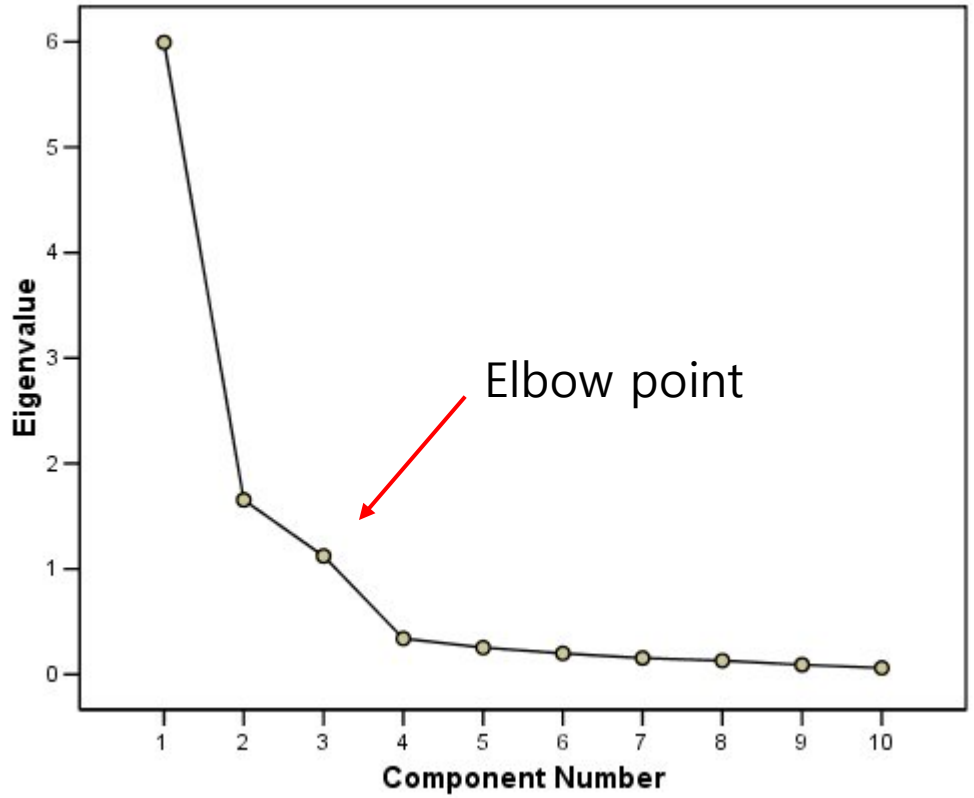

1. Elbow point
   : 곡선의 기울기가 급격히 감소하는 지점

2. Kaiser's Rule
   : 고유값이 1 이상

3. 누적설명률이 70%~80% 이상인 지점

Unit 03 | PCA : Principal Component Analysis

▪ PCA Regression 주성분 회귀분석

PC1 = a11*x1 + a12*x2 + … + a1n*xn

PC2 = a21*x1 + a22*x2 + … + a2n*xn

y* = b0 + b1PC1 + b2PC2
= b0 + b1(a11*x1 + a12*x2 + … + a1n*xn) + b2(a21*x1 + a22*x2 + … + a2n*xn)
= b0 + (b1*a11+b2*a21)x1 + (b1*a12+b2*a22)x2 + (b1*a1n+b2*a2n)xn

➔ **X에 대한 선형 결합**

➔ **범주형자료는 사용 X**

➔ **다른 알고리즘에 PC이용**

※주의사항

Train dataset을 정규화 했으면,
Test dataset을 정규화 할 때는 Train의 mean & std 사용

Unit 03 | PCA : Principal Component Analysis

- PCA Regression 주성분 회귀분석

PC1 = a11*x1 + a12*x2 + … + a1n*xn

PC2 = a21*x1 + a22*x2 + … + a2n*xn

y* = b0 + b1PC1 + b2PC2
= b0 + b1(a11*x1 + a12*x2 + … + a1n*xn) + b2(a21*x1 + a22*x2 + … + a2n*xn)
= b0 + (b1*a11+b2*a21)x1 + (b1*a12+b2*a22)x2 + … + (b1*a1n+b2*a2n)xn

코드로!

➔ X에 대한 선형 결합

➔ 범주형자료는 사용 X

➔ 다른 알고리즘에 PC이용

Unit 03 | PCA : Principal Component Analysis

- PCA의 문제점

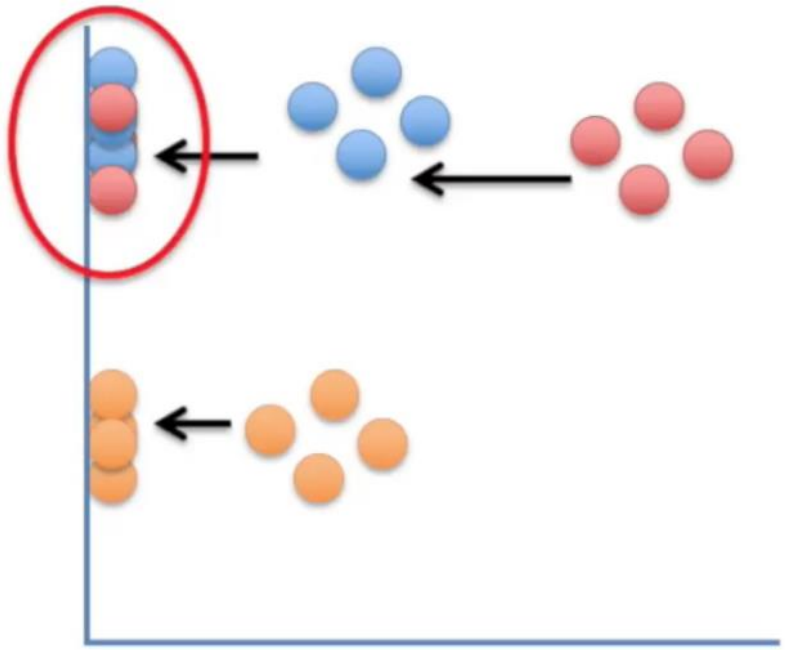

선형으로 데이터를 투영

➔ 군집화 되어있는 데이터들이 뭉게짐

➔ 데이터 사이의 구별이 어려움

➔ 군집의 변별력이 사라짐

Unit 04 | t-SNE : t - Stochastic Neighbor Embedding

- t - Stochastic Neighbor Embedding

  : 고차원에서 데이터 x와 이웃 간의 거리를 최대한 보존하는 저차원의 y를 학습시켜,
  직관적으로 데이터 구조를 확인할 수 있도록 시각화 하는 기법

Unit 04 | t-SNE : t - Stochastic Neighbor Embedding

- t - Stochastic Neighbor Embedding

  : 고차원에서 데이터 x와 이웃 간의 거리를 최대한 보존하는 저차원의 y를 학습시켜,
  직관적으로 데이터 구조를 확인할 수 있도록 시각화 하는 기법

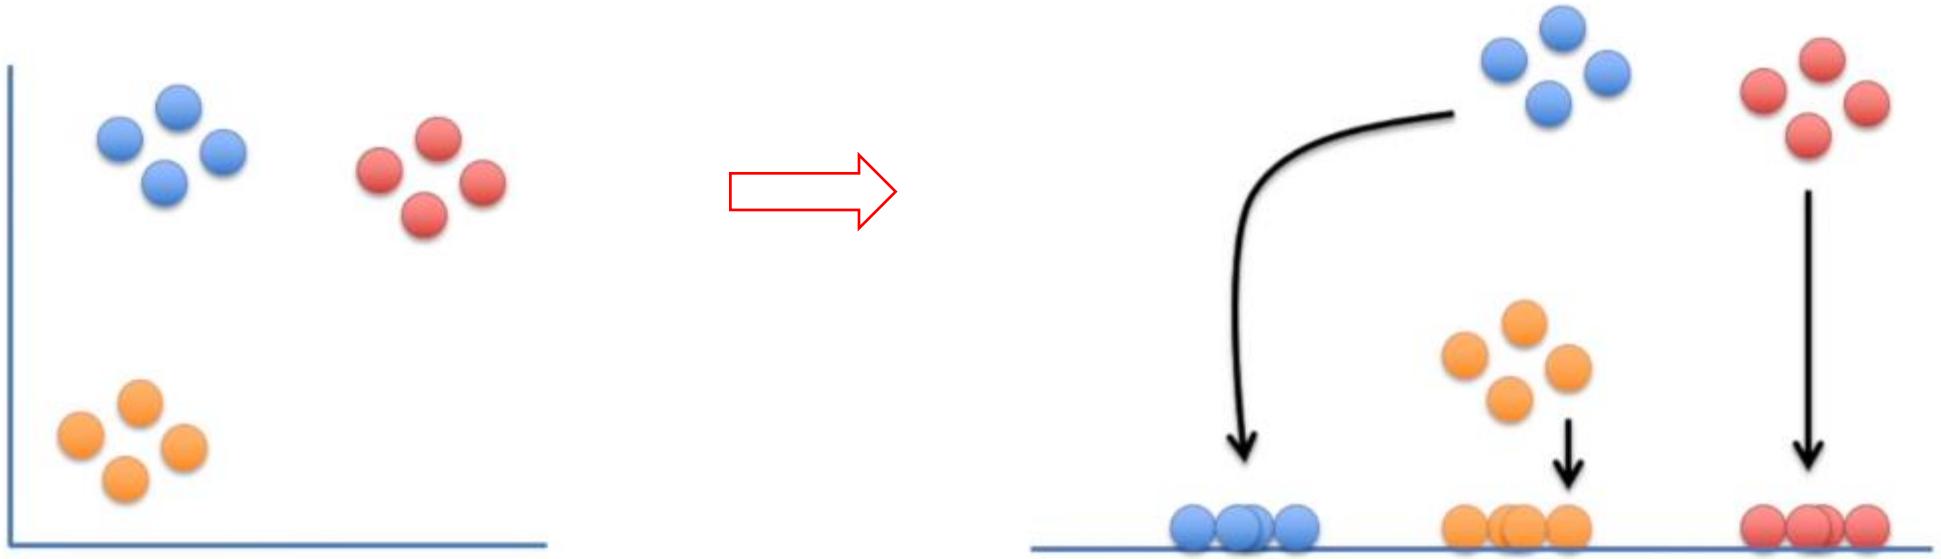

Unit 04 | t-SNE : t - Stochastic Neighbor Embedding

▪ t - Stochastic Neighbor Embedding

: 고차원에서 데이터 x와 이웃 간의 거리를 최대한 보존하는 저차원의 y를 학습시켜,
직관적으로 데이터 구조를 확인할 수 있도록 시각화 하는 기법

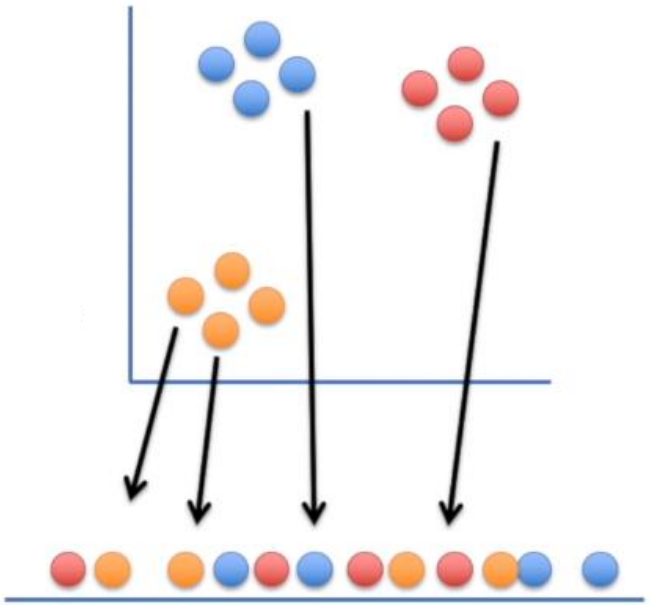

〈t-SNE 과정〉

1. 랜덤하게 배열

Unit 04 | t-SNE : t - Stochastic Neighbor Embedding

▪ t - Stochastic Neighbor Embedding

: 고차원에서 데이터 x와 이웃 간의 거리를 최대한 보존하는 저차원의 y를 학습시켜,
직관적으로 데이터 구조를 확인할 수 있도록 시각화 하는 기법

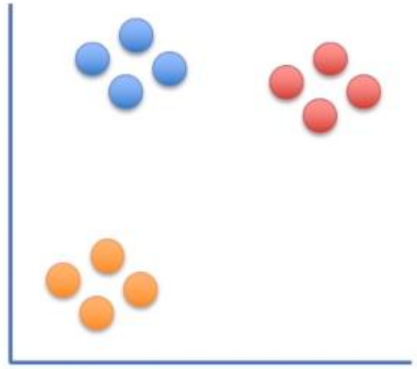

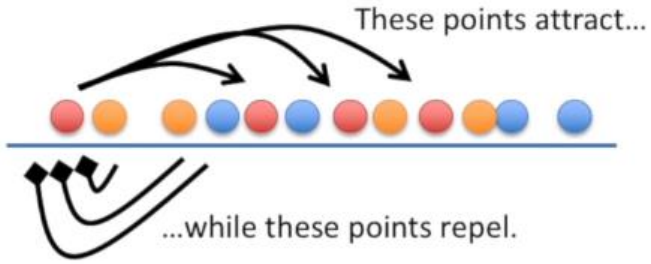

〈t-SNE 과정〉

1. 랜덤하게 배열

2. 동일 군집의 값은 가까이로,
다른 군집의 값은 멀리

Unit 04 | t-SNE : t - Stochastic Neighbor Embedding

▪ t - Stochastic Neighbor Embedding

: 고차원에서 데이터 x와 이웃 간의 거리를 최대한 보존하는 저차원의 y를 학습시켜,
직관적으로 데이터 구조를 확인할 수 있도록 시각화 하는 기법

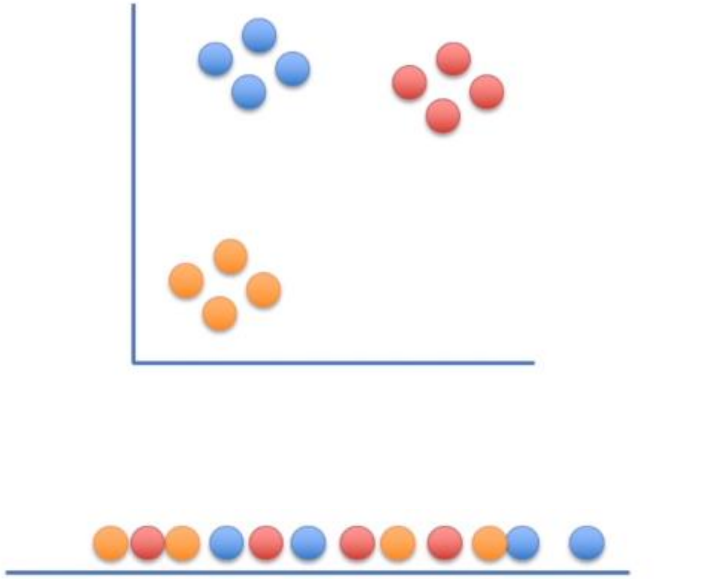

〈t-SNE 과정〉

1. 랜덤하게 배열

2. 동일 군집의 값은 가까이로,
   다른 군집의 값은 멀리

3. 균형이 되는 지점으로 이동

Unit 04 | t-SNE : t - Stochastic Neighbor Embedding

▪ t - Stochastic Neighbor Embedding

: 고차원에서 데이터 x와 이웃 간의 거리를 최대한 보존하는 저차원의 y를 학습시켜,
직관적으로 데이터 구조를 확인할 수 있도록 시각화 하는 기법

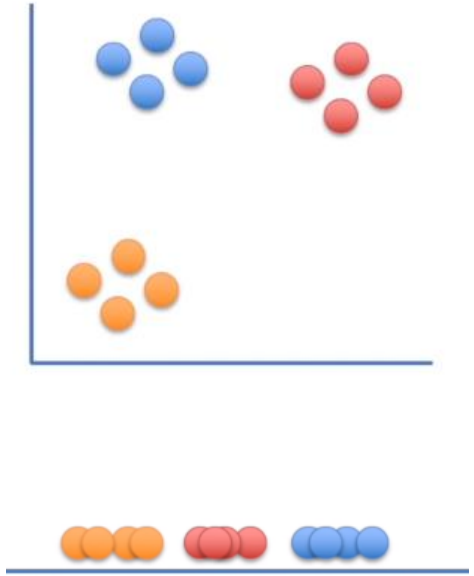

〈t-SNE 과정〉

1. 랜덤하게 배열

2. 동일 군집의 값은 가까이로,
다른 군집의 값은 멀리

3. 균형이 되는 지점으로 이동

4. 2&3 반복 후 군집끼리 가까이 이동

Unit 04 | t-SNE : t - Stochastic Neighbor Embedding

▪ t - Stochastic Neighbor Embedding

: 고차원에서 데이터 x와 이웃 간의 거리를 최대한 보존하는 저차원의 y를 학습시켜,
직관적으로 데이터 구조를 확인할 수 있도록 시각화 하는 기법

➔ 데이터의 군집성 유지

➔ 가까운 이웃(동일 군집 데이터)의 거리만을 유지

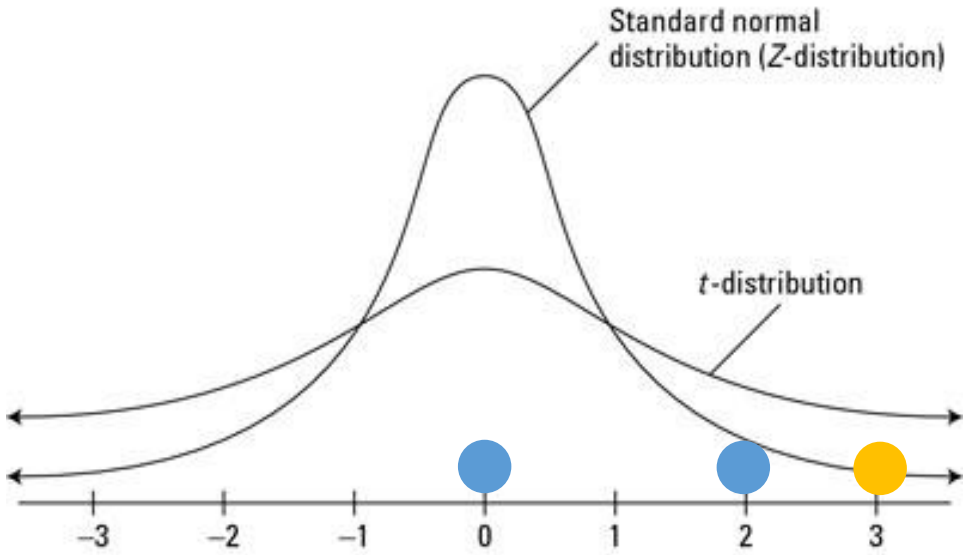

거리 정보를 확률적으로 계산

➔ 저차원의 y를 조금씩 업데이트

정규분포 : 꼬리가 얇아 거리가 일정 수준을 넘으면
매우 작은 값으로 다 확률이 같아짐

➔ 꼬리가 두꺼운 t - 분포를 사용

Unit 04 | t-SNE : t - Stochastic Neighbor Embedding

- t - Stochastic Neighbor Embedding

  : 고차원에서 데이터 x와 이웃 간의 거리를 최대한 보존하는 저차원의 y를 학습시켜,
  직관적으로 데이터 구조를 확인할 수 있도록 시각화 하는 기법

  ➔ 데이터의 군집성 유지

  ➔ 가까운 이웃(동일 군집 데이터)의 거리만을 유지

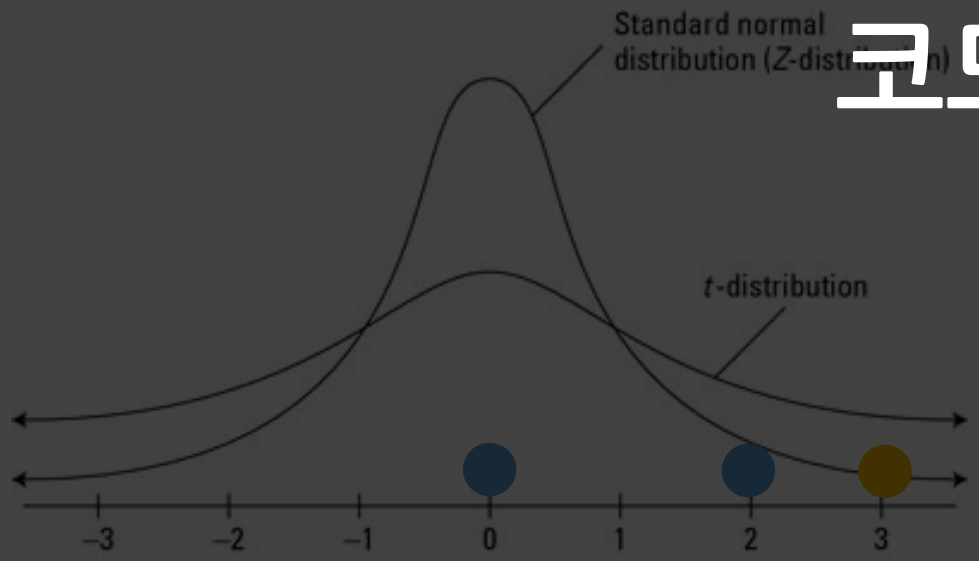

거리 정보를 확률적으로 계산

코드로 !

➔ 저차원의 y를 조금씩 업데이트

정규분포 : 꼬리가 얇아 거리가 일정 수준을 넘으면
매우 작은 값으로 다 확률이 같아짐

➔ 꼬리가 두꺼운 t - 분포를 사용

Unit 04 | t-SNE : t - Stochastic Neighbor Embedding

▪ t - Stochastic Neighbor Embedding

: 고차원에서 데이터 x와 이웃 간의 거리를 최대한 보존하는 저차원의 y를 학습시켜,
직관적으로 데이터 구조를 확인할 수 있도록 시각화 하는 기법

➔ 데이터의 군집성 유지

➔ 가까운 이웃(동일 군집 데이터)의 거리만을 유지

※ 문제점

계속 업데이트하는 방식으로 변형된 값이 매번 바뀜

➔ t-SNE 결과를 새로운 feature로 사용 불가능

군집만 유지하고 값이 완전히 변화

Unit 05 | Assignment

Q1. PCA를 직접 구현한 myPCA

Q2. 단어 임베딩 벡터 시각화
- ➔ kmeans로 n=10 군집화
- ➔ 차원축소 전 데이터로 시각화
- ➔ PCA & TSNE로 시각화

Q3. 축소 전 데이터와 PCA축소 데이터 training 시간 비교
- ➔ train 데이터 로드 후 train과 test(20%) 로 split
- ➔ 원본 데이터로 knn과 svm 적용 + 타임스탬프
- ➔ 축소 데이터로 knn과 svm 적용 + 타임 스템프
- ➔ training 시간 비교 & test accuracy 비교

Unit 05 | Assignment

Q2 결과

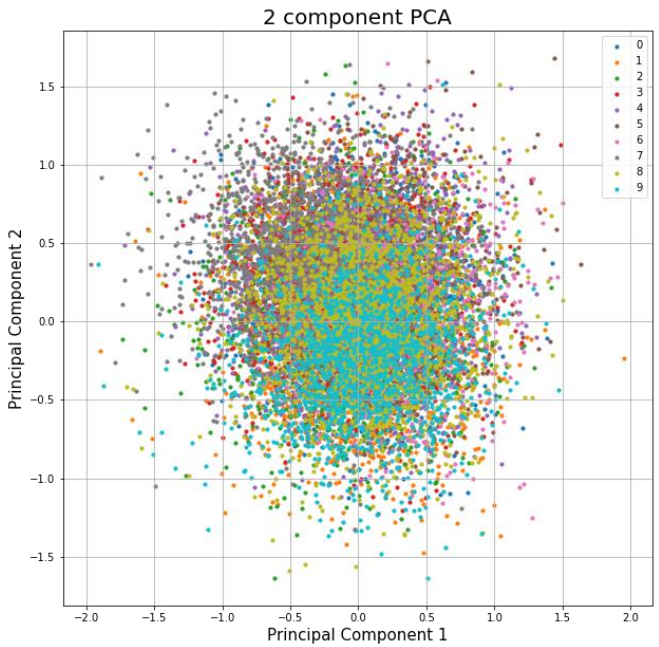

원본

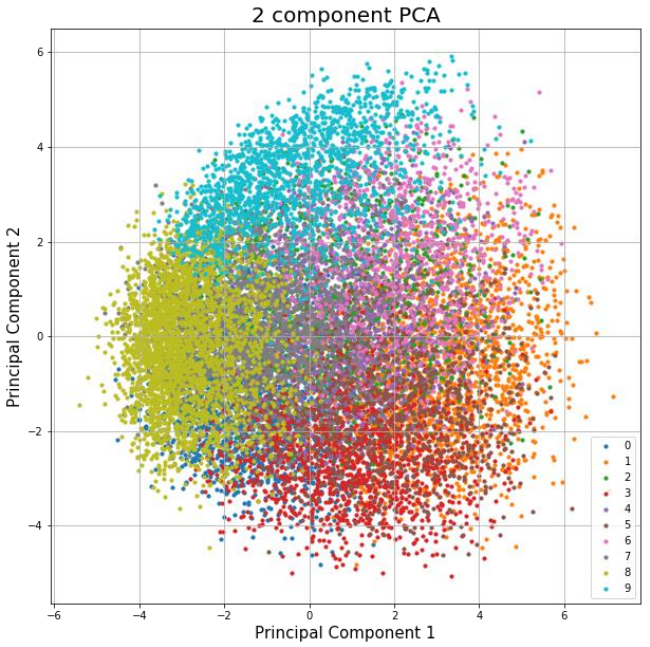

PCA

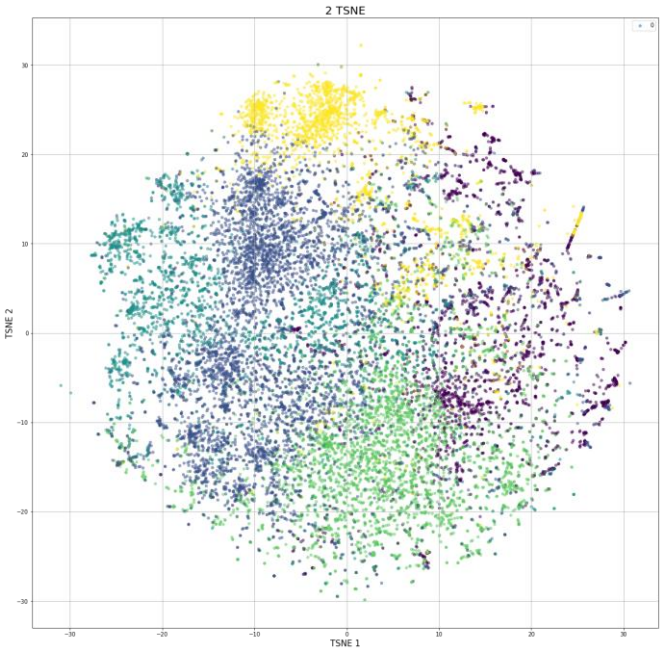

TSNE (비슷한 느낌)

Unit 00 | 참고자료

공돌이의 수학정리노트 ➔ 자세한 수학적 접근
PCA : https://wikidocs.net/7646
Eigen : https://wikidocs.net/4050

ratsgo's blog ➔ 상세한 예시와 R코드
PCA : https://ratsgo.github.io/machine%20learning/2017/04/24/PCA/
t-SNE : https://ratsgo.github.io/machine%20learning/2017/04/28/tSNE/

조대협의 블로그 ➔ Python 코드
PCA : https://bcho.tistory.com/1209?category=555440
t-SNE : https://bcho.tistory.com/1210

꼬깔콘의 분석일지 ➔ 차원의 저주
https://kkokkilkon.tistory.com/127

t-SNE 관련 youtube
https://www.youtube.com/watch?v=NEaUSP4YerM

책 : 응용다변량분석 (성웅현)

들어주셔서 감사합니다.